
生成模型導論(一)

分布的度量與調控

兩種常見的輸出

同一段開頭:「我最近壓力很大，一直睡不好。」

base model 續寫三次(示意樣本)

- 「...一直睡不好，而且早上起來頭很脹。上禮拜去看了醫生，醫生說...」
- 「...一直睡不好。回覆 #2：我也是，從去年換工作就開始這樣。回覆 #3：+1」
- 「...一直睡不好。睡眠品質與壓力的關係是雙向的，長期壓力會...」

aligned model 回覆三次(示意樣本)

- 「聽起來這段時間辛苦了。以下三個建議：1. 固定作息...」
- 「聽到這些感到很心疼。以下幾個方向：1. 建立睡前儀式...」
- 「這段時間辛苦了。可以試試：1. 規律作息...」

左側把開頭當文本接下去：替說話者把話說完、跑成論壇串、轉進衛教文章，各次分歧而不對話。右側每次都在回答，而且幾乎同一個模板。這兩種行為有共同的來源。

課程重點

base model 的含糊迴避 與 aligned model 的千篇一律

—mode-covering—

—mode-seeking—

是同一個量的兩個極端：模型分布的覆蓋程度，也就是機率質量攤在多少種輸出上。

本堂課給出這個主張的論證，並指出覆蓋程度可以在哪些層次上調整。

實驗室題目背後的機率問題

實驗室相關的六個題目，六個關於分布的陳述

題目	背後的機率問題
prompt engineering	選擇條件變數 c ，操縱 $p(y \mid c)$
memory agent	建構條件集合；長脈絡下 $p(\text{task} \mid \text{context})$ 被稀釋
情感支持對話	泛泛安慰語與對齊後的多樣性塌縮
false assumptions 偵測	$p(y \mid x)$ 永遠良定義，即使 $p(x) \approx 0$
信心與正確率	模型報出的機率能不能被信任(校準)
ASR	嘗試解構出 $p(\text{feature} \mid \text{audio})$ 來降低 ASR 建模難度： $p(\text{text} \mid \text{audio}) = \int_{\text{feature}} p(\text{text} \mid \text{feature}, \text{audio}) p(\text{feature} \mid \text{audio}) ;$

兩堂課處理的正是：分布如何度量、如何調控、如何建造。

判別式與生成式

一個學標籤的條件分布，一個學資料分布本身

判別式模型

學 $p(y | x)$

輸出空間小而封閉：類別、分數、標籤

生成式模型

學一個可以抽樣的 $p_{\theta}(x)$, 或條件版 $p_{\theta}(x | c)$

目標：逼近未知的 p_{data}

「逼近」馬上引出兩個問題：

1. p_{θ} 與 p_{data} 的差距要用什麼量來度量？
2. 度量所需要的資訊, 雙方拿不拿得出來？

高維分布無法列表

列舉所有狀態的成本隨維度指數成長

一張 256×256 的二值影像，狀態總數：

$$2^{256 \times 256} = 2^{65536} \approx 10^{19728}$$

把每個狀態的機率存成一張表：宇宙的原子數($\approx 10^{80}$)遠遠不夠。詞彙表 5 萬的 100-token 句子同理： 50000^{100} 個狀態。

因此分布只能以「函數 + 參數」的形式存在，而能對它做的事取決於這個函數形式能回答哪些問題。

介面契約

一個分布,至多提供兩個可呼叫的介面

分布 p 作為一個物件

`p.sample()` → 從 p 抽出一個樣本


`p.logprob(x)` → 回傳 $\log p(x)$

本堂所有操作都只透過這兩個介面進行。每引入一個方法,先問它呼叫了哪個介面。

兩個介面的動作

`sample()` 交出一個樣本，`logprob(x)` 交出指定點的對數密度

p 的密度曲線(模型內部持有的函數)



`p.sample()` 抽出一個 x ，落點的疏密正比於密度

`p.logprob(x)` 給定一個 x ，回報該處密度的對數

介面盤點

資料側與模型側，各自能回答什麼

物件	<code>sample()</code>	<code>logprob(x)</code>
p_{data} (資料)	有：資料集就是樣本的集合	無：資料不附帶密度
p_{θ} (模型)	本堂假設有	本堂假設有

資料給的是樣本，沒有密度

逼近需要選擇散度

量差距的方式決定犯錯的方式

KL divergence

以 p 為權重的對數比期望

$$\text{KL}(p \parallel q) = \int p(x) \log \frac{p(x)}{q(x)} dx$$

積分由 p 加權：只在 p 有質量的地方量測差異。 p 幾乎為零的區域，無論 q 在那裡放了多少機率，都幾乎不進入積分。


把 p_{data} 和 p_{θ} 分別放進兩個位置，得到兩個不同的目標：

- $\text{KL}(p_{\text{data}} \parallel p_{\theta})$: Forward KL
- $\text{KL}(p_{\theta} \parallel p_{\text{data}})$: Reverse KL

Forward KL：覆蓋是義務

權重在 p_{data} 手上

$$\text{KL}(p_{\text{data}} \parallel p_{\theta}) = \int p_{\text{data}} \log \frac{p_{\text{data}}}{p_{\theta}}$$



積分由 p 加權： p 有質量而 q 沒有的區域主導損失， q 被迫覆蓋 p 的整個支撐集(zero-avoiding)


凡 $p_{\text{data}} > 0$ 而 $p_{\theta} \rightarrow 0$ 之處，懲罰無上界，所以 p_{θ} 必須覆蓋 p_{data} 的整個支撐集：**zero-avoiding / mode-covering**。代價是把機率質量攤到峰與峰之間的低密度區。

以 forward KL 訓練的語言模型對每種說法都留一點機率,不讓任何一種降到零：開場看到的含糊、發散的續寫,就是這個目標下的合理行為。

Reverse KL：放棄不罰

權重換到 p_θ 手上

$$\text{KL}(p_\theta \parallel p_{\text{data}}) = \int p_\theta \log \frac{p_\theta}{p_{\text{data}}}$$



積分由 q 加權：q 沒去的地方不進入積分，丟掉整個峰不付代價(zero-forcing)

p_θ 不去的地方不進積分，整個丟掉 p_{data} 的一個眾數不付任何代價；但 p_θ 涉足 p_{data} near-zero 區則重罰。zero-forcing / mode-seeking。

對齊後的模型回答收斂到少數幾種安全模板、多樣性下降，是 mode-seeking 目標的行為特徵。

JSD 的定義

以混合分布 m 當共同分母

$$\text{JSD}(p \parallel q) = \frac{1}{2} \text{KL}\left(p \parallel m\right) + \frac{1}{2} \text{KL}\left(q \parallel m\right), \quad m = \frac{p+q}{2}$$

與「對稱化 KL」(Jeffreys divergence) $\text{KL}(p\parallel q) + \text{KL}(q\parallel p)$ 不同：Jeffreys 繼承兩側的無窮大；JSD 的分母是混合 m ，只要 p 或 q 有質量, m 就有質量，因此

性質	說明
有界	$0 \leq \text{JSD} \leq \log 2$
對稱	定義即對稱
度量	$\sqrt{\text{JSD}}$ 滿足度量公理(Endres & Schindelin, 2003)

有界的代價：飽和

支撐集一旦分離,曲線就貼著上界



兩個高斯的峰間距 d (標準差 = 1)

數值積分結果：兩個單位高斯相距 d 時的 JSD。支撐集實際分離後，再拉遠也幾乎不再增加。

JSD 的判別器讀法

把散度改寫成一個可訓練的分類問題

以等量樣本訓練一個分類器，判斷樣本來自 p 還是 q 。最優判別器有閉式解：

$$D^*(x) = \frac{p(x)}{p(x) + q(x)}$$

把 D^* 代回二元分類目標，其值為 $2 \text{JSD}(p \parallel q) - 2 \log 2$ 。換句話說：**JSD 度量的是最優分類器分辨兩個來源的能力**。兩個分布重疊得越好，最優分類器越接近亂猜，JSD 越小。


同一個式子的等價寫法：

$$D^*(x) = \sigma\left(\log \frac{p(x)}{q(x)}\right) \quad (\text{sigmoid} \equiv \log \text{ratio} \equiv)$$

選擇散度,就是選擇可接受的錯誤

三種選擇,三種失效型態

	forward KL	JSD	reverse KL
行為	mode-covering	介於其間，但會飽和	mode-seeking
對稱	否	是	否
上界	無	$\log 2$	無
失效型態	過度平滑、含糊	梯度消失或震盪	塌縮、多樣性流失



圖中的橫向位置就是覆蓋程度：左端把質量攤給每一種子集，右端集中在少數幾種。

單峰 q 擬合雙峰 p:三種散度,三種解 ↗

目標分布 p 雙峰(等權) ▾

模型容量 K 1(單一高斯) ▾

目標散度 Forward KL(MLE) ▾

λ 0.50

訓練速度 4

▶ 開始訓練


↺ 重設 q

☒ q 的等高橢圓 ☒ q 的樣本

step 0 Fwd KL 2.03 Rev KL 4.65 JSD 0.385 □ 0/2

資料空間 $x \in \mathbb{R}^2$


藍綠色點=從目標 p 取的樣本(色相=它屬於哪一個成分)。橘紅點=從 q 取的樣本。橘紅橢圓=q 各成分的 $1\sigma/2\sigma$, 線越粗代表該成分權重越大。橢圓塌到單一群上,就是 mode-seeking 的現場。



● 目標樣本 p ● 模型樣本 q ○ q 的成分橢圓

最佳判別器地景 $D^*(x)$ (可點擊查詢)


這裡畫的是 $D^*(x) = p/(p+q) = \sigma(\log p - \log q)$ —— GAN 要訓一整個網路來估的東西,在這裡是算得出來的。藍=p 多於 q(模型漏掉了),橘=q 多於 p(模型多放了)。forward KL 罰藍區,reverse KL 罰橘區。



● $D^*(x)$: 0(橘, q 亂放) → 1(藍, q 漏掉) ● 查詢點

三種散度同時量(只最小化其中一種)

不論正在最小化哪一個,三條曲線都同時被計算。最佳化 reverse KL 時,盯著 forward KL 怎麼往上飛——那就是被犧牲掉的覆蓋度。虛線是 JSD 的上界 $\log 2 \approx 0.693$, 它永遠碰不到天花板以上。



● Forward KL ● Reverse KL ● JSD

mode-covering ○

mode-seeking

每個散度需要哪些介面

同一份介面清單，三種可得性

散度	需要的介面	可得性
forward KL $\text{KL}(p_{\text{data}} p_{\theta})$	$p_{\text{data}}.\text{sample} + p_{\theta}.\text{logprob}$	兩者皆有
reverse KL $\text{KL}(p_{\theta} p_{\text{data}})$	$p_{\theta}.\text{sample} + p_{\theta}.\text{logprob} + p_{\text{data}}.\text{logprob}$	末項不可得
JSD(由雙側密度的混合構成)	兩側 logprob	資料側必缺

forward KL 是唯一所需介面皆可得的散度：期望用 p_{data} 的樣本近似，被積函數只呼叫 $p_{\theta}.\text{logprob}$ 。


reverse KL 與 JSD 缺的是同一個介面： p_{data} 沒有 logprob。

課後練習

以單一高斯擬合雙峰混合，三種散度各解一次


以單一高斯 $q = \mathcal{N}(\mu, \sigma^2)$ 擬合 1D 雙峰混合 $p = \frac{1}{2}\mathcal{N}(-2, 0.6^2) + \frac{1}{2}\mathcal{N}(2, 0.6^2)$ ，分別最小化三種散度並解出 μ, σ 。

forward KL




覆蓋兩峰,質量填進峰間空隙

JSD



介於兩者之間的折衷

reverse KL



鎖定單一眾數,放棄另一峰

— 雙峰目標 p — 單一高斯 q (該散度下的解)

預期結果如上圖。動手做一遍，三種行為就不再只是形容詞。

分布固定之後

目標分布往往不是模型分布本身：更符合條件、更銳利、更安全、更多樣

引導生成的統一形式

base 項、比值項、係數，三個欄位

$$\log p_{guided} = \log p_{base} + w (\log p_A - \log p_B)$$

base 項

出發的分布

prompt 改動的就是這一項

係數

移動的幅度

越大越往 mode-seeking 端

比值項

移動方向

抬高 p_A 相對 p_B 偏好的區域

計算完成後再正規化；整條式子只呼叫 logprob 介面

常見方法都是這條式子(上)

解碼期常見的四種手法

方法	base	比值項	係數	需要的介面
temperature	$\log p$	無	$1/T$	logprob(逐 token)
CFG for LLM Sanchez et al., 2023	$\log p(x \mid c)$	$\log p(x \mid c) - \log p(x)$	w	兩種條件下的 logprob
contrastive decoding Li et al., 2023, Autoguidance Karras et al., 2024	$\log p_{\text{strong}}$	$\log p_{\text{strong}} - \log p_{\text{weak}}$	λ	兩個模型的 logprob
DoLa Chuang et al., 2024	$\log p_{\text{final}}$	末層與淺層 logits 之差	λ	中間層 logits

常見方法都是這條式子(下)

劣化模型、偏好對齊、分布銳化

方法	base	比值項	係數	需要的介面
RLHF 最優解 Ouyang et al., 2022;推導見 Rafailov et al., 2023	$\log \pi_{\text{ref}}$	$r(y)$	$1/\beta$	ref 的 logprob + reward
DDO 最優解 Zheng et al., 2025	$\log p_{\text{ref}}$	$\log p_{\text{data}} - \log p_{\text{ref}}$	$1/\beta$	兩者的 logprob

top-k / top-p 是同一操作的硬截斷版：不連續，但同樣在移除尾部機率質量。

同一根滑桿:temperature、CFG、contrastive decoding [↗](#)

$$\log p_{\text{guided}} = \log p_{\text{base}} + w \cdot (\log p_A - \log p_B) \quad (\square \text{ renormalize})$$


Temperature

CFG

Contrastive Decoding

Prompt Engineering

w = 1/T




1.0

☐ 對數空間檢視

H(guided) 3.235 bits top-1 36.7%  0.0% T = 1.00

next-token 分布(20 個候選 token)

base=均勻分布(全零 logits),A=一般 next-token logits、B=0,於是 w 就字面上等於 1/T:guided logits = $\log p / T$ 。w=1 是原始分布(灰色參考長條);w 往右 $\rightarrow T$ 變小 $\rightarrow$ 分布變尖;w 往左 $\rightarrow T$ 變大 $\rightarrow$ 分布往均勻攤平,w=0 時完全均勻。



三個結論

位置、時機、適用範圍

1. **係數決定移動的幅度**。 w 或 $1/\beta$ 越大, 比值項的作用越強；各方法的控制參數都填在式子的同一欄，移動的方向則由各自的比值項決定。
2. **推論期做與訓練期做, 差別只在時機**。同一條式子可以在解碼時套用，也可以內化進權重(第④節)。
3. **適用範圍由介面決定**。上兩頁的每一列幾乎都要呼叫 `logprob`；不提供 `logprob` 的模型或黑箱就無法在推論期操作分布。

mode-covering

廣覆蓋、過度平滑

mode-seeking

銳利、可能丟失眾數

訓練目標

forward KL • MLE

JSD

reverse KL • RLHF

解碼設定

temperature $T > 1$

$T = 1$

收緊 top-p • 調高 CFG 係數

討論:prompt 在式子的哪個位置

三個欄位,提示詞只動得了一個

$$\log p_{\text{guided}} = \underbrace{\log p_{\text{base}}}_{\text{prompt 欄位}} + w (\log p_A - \log p_B)$$

prompt engineering 改變條件 c ，等於整個換掉 base 項；係數 w 與比值項完全不動。

因此：輸出太單調、太發散、過度銳化這類**係數層次的問題**，**無法靠改寫 prompt 解決**，提示詞不在那個位置上。

討論：平常用 LLM 時，有沒有遇過「怎麼改 prompt 都沒改善」的情況，其實出在係數這一欄？

中場 Q & A

推論期的四層介入

從條件到聚合，每一層呼叫的介面不同

四層總覽

四個介入點,各自呼叫不同的介面

層	介入點	方法	所需介面
1	改變條件 c	prompt • few-shot • RAG • memory	僅 sample(條件版)
2	改變抽樣	temperature • top-k / top-p / min-p • beam	logprob(逐 token)
3	改變 logits	logit bias • constrained decoding • contrastive decoding • DoLa • CFG	logprob(逐 token)
4	改變樣本聚合	self-consistency • best-of-n • MBR • reranking	sample(logprob 可選)

第 1 層與第 4 層只需要 sample:任何黑箱 API 都能做。這正是 prompt engineering 與多數投票類方法對任何服務都可行的原因。

第 1 層.改變條件:prompt 即 conditioning

示範收緊的是任務的後驗

$$p(y \mid \text{prompt}) = \int p(y \mid \text{task}) p(\text{task} \mid \text{prompt}) d\text{task}$$

In-context learning 可讀成隱式貝氏推論([Xie et al., 2022](#))：prompt 裡的示範不改參數，而是收緊模型對「現在在做哪個 task」的後驗。


memory agent 的機率語意:記憶系統的工作是**挑選哪些證據進入後驗**;存放只是實作手段。

RAG 與 fine-tuning：兩種安裝條件的方式

條件留在脈絡裡,或攤銷進權重

	RAG	fine-tuning
機率意義	顯式條件： $p(y \mid x, \text{context } d)$	條件攤銷進權重： $p_{\theta'}(y \mid x)$
失效型態	檢索錯, 條件就錯：無關文件稀釋後驗	分布外遺忘：更新成本高、不可逆


「無關文件稀釋後驗」有量化證據:關鍵資訊放在長脈絡中段時,取用正確率明顯下降(*lost-in-the-middle*, [Liu et al., 2024](#))。更多條件不等於更好的條件， $p(\text{task} \mid \text{prompt})$ 會被攤平。



20 份檢索文件，答案所在位置由開頭移到中段，正確率從 75.8% 掉到 54%，中段甚至低於完全不給文件的 closed-book 基線(紅虛線)。

第 2 層.改變抽樣

同一組 logits, 兩種重塑方式



同一組 logits。temperature 連續改變熵; top-p 把尾部質量直接移除後再正規化。

temperature 把 logits 除以 T ，直接調整分布的熵；top-p 截斷尾部後再正規化([Holtzman et al., 2020](#))。

抽樣設定是一個設計決策：低 T 安全而單調，高 T 多樣而風險高。

mode-covering

廣覆蓋、過度平滑

mode-seeking

銳利、可能丟失眾數

訓練目標

forward KL • MLE

JSD

reverse KL • RLHF

解碼設定

temperature $T > 1$

$T = 1$

收緊 top-p • 調高 CFG 係數

第 3 層.改變 logits

在 softmax 之前修改分數

- **constrained decoding / grammar:** 在合法 token 子集上重新正規化。要求結構化輸出(JSON、SQL)時，這比在 prompt 裡以指示要求格式可靠：非法 token 的機率被精確歸零，軟性指示做不到這一點。
- **logit bias:** 對特定 token 加減常數，即統一引導式中一個手寫的比值項。
- **contrastive decoding、DoLa、CFG for LLM:** 上一節表中的三列，透過逐 token 修改 logits 後再 softmax。

第 4 層.改變樣本的聚合

抽多個『完整』樣本，重新估計答案的分布

- **Best-of-n**: 抽 n 個，用外部評分挑一個
- **Self-consistency**: 抽多條推理路徑，對最終答案投票
- **MBR**(minimum Bayes risk): 選「與其他樣本平均距離最近」的輸出
- **Reranking**: 以另一個模型重排候選

Self-consistency 的機率語意即 Monte Carlo 邊際化： $p(a | q) = \sum_r p(a | r, q) p(r | q)$ ，對推理路徑 r 積分 ([Wang et al., 2023](#))。

classifier guidance:分類器提供比值項

無條件模型與分類器兩個介面都拿得到,貝氏反轉才寫得出來

$$\log p_w(x) = \log p(x) + w \log p(c | x)$$

由貝氏, $\log p(c | x) = \log p(x | c) - \log p(x) + \text{const}$ ：分類器交出來的就是那個比值項。base 項是無條件模型，係數是 guidance scale w ；安裝位置在第 3 層，逐步修改分數 ([Dhariwal & Nichol, 2021](#))。

w	得到的分布
0	無條件分布 $p(x)$
1	貝氏後驗 $p(x c)$ ，因為 $p(x)p(c x) = p(x, c)$
> 1	外插：條件更銳利，多樣性下降

代價是一個額外介面： $p(c | x)$ 要另外訓練。CFG 把比值項改由同一個模型跑有條件與無條件兩次算出，這個額外介面就不需要了([Ho & Salimans, 2022](#))。

classifier guidance:w=0 無條件,w=1 後驗,w>1 外插 ↗

$$\log p_w(x) = \log p(x) + w \cdot \log p(c|x) \quad \log p(c|x) = \log p(x|c) - \log p(x) + \text{const}$$

類別 A

類別 B

類別 C

guidance scale w 0.00

☒ 顯示樣本


13.05 bits

35.3%

$\|p_w - p(\cdot|c)\|_1$ 1.191

無條件分布 $p(x)$


三個類別的混合。base 項就是它,與 w 無關。



A $\pi=0.45$ B $\pi=0.35$ C $\pi=0.20$

分類器 $p(c|x)$


所選類別的後驗機率,深色為 1、淺色為 0;虛線是 0.5 的決策邊界。這張圖也與 w 無關。



比值項 = $\log p(c|x)$

引導後 $p_w(x)$

w=0 完全沒有引導,這張圖就是左邊那張 $p(x)$ 。



樣本 250 點,由格點分布抽出

Demo 01 統一式 $\log p_{\text{guided}} = \log p_{\text{base}} + w \cdot (\log p_A - \log p_B)$

classifier guidance $\log p_w = \log p(x) + w \cdot \log p(c|x)$,而 $\log p(c|x) = \log p(x|c) - \log p(x) + \text{const}$

對應關係:無條件模型是 base;分類器就是比值項,因為由貝氏它本來就等於「條件減無條件」;w 是統一式裡的係數。代價是一個額外介面: $p(c|x)$ 要另外訓練。CFG 把比值項改成同一個模型跑有條件與無條件兩次,分類器就不需要了。

後訓練的介入

SFT、RLHF、DPO、DDO：把移動寫進參數

SFT: 在新資料上重做 MLE

換資料, 不換目標函數

$$\max_{\theta} \mathbb{E}_{(x,y) \sim \mathcal{D}_{\text{SFT}}} [\log \pi_{\theta}(y \mid x)]$$

目標函數與預訓練相同，仍是 forward KL，只是換了資料分布，透過顯式把分布遷移到一個較小的子集上, 能減輕原先過度通用的特性。但有對新子集 mode-covering 的可能性。

mode-covering 廣覆蓋、過度平滑		mode-seeking 銳利、可能丟失眾數	
訓練目標	forward KL • MLE	JSD	reverse KL • RLHF
解碼設定	temperature $T > 1$	$T = 1$	收緊 top-p • 調高 CFG 係數
權重微調	SFT(仍是 MLE)		DPO • 小 β

RLHF 的目標與閉式解

reward 的期望,減去與參考模型的 KL

$$\max_{\pi} \mathbb{E}_{y \sim \pi} [r(y)] - \beta \text{KL}(\pi \parallel \pi_{\text{ref}})$$

這個目標有閉式最優解(推導見 [Rafailov et al., 2023](#) 附錄；把解代回目標即可驗證)：

$$\pi^*(y) \propto \pi_{\text{ref}}(y) \exp(r(y)/\beta)$$

取 log 即第②節表中的 RLHF 列。而整個最佳化問題等價於

$$\min_{\pi} \text{KL}(\pi \parallel \pi^*)$$

KL 的第一個位置放的是 π ，這正是 reverse KL：對齊訓練落在 mode-seeking 端。

DPO:把 reward 消掉

模型自己的 log ratio 就是隱式 reward

閉式解可以反過來解出 reward：

$$r(y) = \beta \log \frac{\pi^*(y)}{\pi_{\text{ref}}(y)} + \text{const}$$

把這個表達式代入偏好資料的 Bradley-Terry 損失，reward model 從式子裡消失([Rafailov et al., 2023](#)):

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w)}{\pi_{\text{ref}}(y_w)} - \beta \log \frac{\pi_{\theta}(y_l)}{\pi_{\text{ref}}(y_l)} \right) \right]$$

整條損失只呼叫 π_{θ} 與 π_{ref} 的 logprob 介面；最佳化的仍是同一個 reverse KL 目標。

reward model 補的是哪一格

reverse KL 缺的那一個介面

散度	缺的介面	補上它的東西
reverse KL	目標分布的 logprob	reward model

需求表裡標「不可得」的那一格，由 reward model 填補:它從人類偏好標註學出純量分數 $r(y)$ ，而 r/β 正好充當目標分布相對 π_{ref} 的 log 密度比。

要注意目標分布在此換了對象：對齊瞄準的已非 p_{data} ，而是偏好加權後的 $\pi^* \propto \pi_{\text{ref}} e^{r/\beta}$ 。
缺 logprob 的困境不變，代理的品質決定對齊的品質：reward model 學壞了， π^* 就指向錯的地方(reward hacking)。

β 是唯一抑制塌縮的項

單調來自目標函數的形式

「對齊讓模型更安全，但更單調」可以從目標函數推出，不是經驗巧合：

- reverse KL 目標的最優解只在 reward 高的區域放質量；多樣性沒有出現在目標函數裡
- 唯一抑制塌縮的是 $\beta \text{KL}(\pi \parallel \pi_{\text{ref}})$ ，而它約束的是與參考模型的距離，不是多樣性本身
- 實測：RLHF 後輸出多樣性系統性下降([Kirk et al., 2024](#))

β 的取捨問題：調鬆帶來變化也帶來不受控的風險，調緊帶來安全也帶來模板。

逐點計分器的結構極限

reward model 與 judge 共有的限制

reward model 對**單一**樣本給分： $r(y) \in \mathbb{R}$ 。

「這個分布太窄」是**分布層級**的性質，單點分數的介面裡沒有承載它的欄位：

每個模板回答逐點看都得高分,計分器對「全部都是同一種回答」無從抗議。

LLM-as-judge 同樣逐點評審，同樣的極限；把 judge 換強並不補上這個欄位。

因此抑制塌縮的只剩 β 項對參考模型距離的約束。

兩件已經在手上的事實

一個判別器閉式解，一條引導式

事實一(第①節) 分辨兩個分布的最優判別器是

$$d^*(x) = \sigma \left(\log \frac{p_{\text{data}}(x)}{q(x)} \right)$$

事實二(第②節) 統一引導式方法表的末列:

$$\log p_{\text{guided}} = \log p_{\text{ref}} + \frac{1}{\beta} (\log p_{\text{data}} - \log p_{\text{ref}})$$

接下來的方法只用這兩件事，不引入任何新原理。

DDO：用自己的 logprob 當判別器

判別器不必是另一個網路

任何提供 logprob 的分布，都可以直接宣告自己是判別器([Zheng et al., 2025](#)):

$$d_{\theta}(x) = \sigma\left(\beta \log \frac{p_{\theta}(x)}{p_{\text{ref}}(x)}\right)$$

- β 是必要的縮放：log ratio 的逐維差異隨維度累積、量級可達數十至數百,直接進 sigmoid 會使梯度消失
- 以標準 BCE 訓練：真樣本標 1, 參考模型樣本標 0
- BCE 的最優判別器是 $\sigma(\log(p_{\text{data}}/p_{\text{ref}}))$ ：對照兩式, $\beta = 1$ 時最優解就是 $p_{\theta} = p_{\text{data}}$, 一般 β 給出 $p_{\theta}^* \propto p_{\text{ref}}^{1-1/\beta} p_{\text{data}}^{1/\beta}$

DDO 把 reward 參數化成 log ratio；DDO 把**判別器**參數化成 log ratio。參數化手法相同，套用的對象不同。

DDO 的機制

兩種樣本，一個 BCE 損失



無需額外判別器網路、無需交替訓練、無需對抽樣過程反向傳播。

梯度在做什麼

正負號由 p_θ 與 p_{data} 的差決定

$$\nabla_\theta L = \int (1 - d_\theta(x)) (p_\theta(x) - p_{\text{data}}(x)) \nabla_\theta \log p_\theta(x) dx \quad (\text{if } \beta = 1)$$

區域	符號	作用
$p_\theta < p_{\text{data}}$ (蓋不夠)	負	抬升該處密度
$p_\theta > p_{\text{data}}$ (蓋過頭)	正	壓低該處密度

MLE 的梯度只有第一種作用：在資料點上抬密度，對模型自己多出來的機率質量沒有任何移除機制。DDO 的損失同時含 $\mathbb{E}_{p_{\text{data}}}[\cdot]$ (抬) 與 $\mathbb{E}_{p_{\text{ref}}}[\cdot]$ (壓)，「遠離自己的樣本」的精確意義在此。

MLE 與 DDO 的梯度場 ↗



播放



重設

學習率 η



1.0



對數縱軸




self-play:每 50 步更新 p_{ref} (進階)

step 0 · $\beta = 2$

左:MLE(forward KL)


$\nabla_{\theta} L = - \int p_{data}(x) \nabla_{\theta} \log p_{\theta}(x) dx \rightarrow$ 權重 $= p_{data}(x) \geq 0$ 。峰間殘餘質量只能靠 softmax 正規化被動稀釋,退得很慢。



forward KL **0.9269** reverse KL **1.8131** ☐☐☐☐ 34.9%

右:DDO(隱式判別器)

$\nabla_{\theta} L = \int (1-d_{\theta})(p_{\theta}-p_{data}) \nabla_{\theta} \log p_{\theta} dx, d_{\theta} = \sigma(\beta \cdot \log p_{\theta}/p_{ref}) \rightarrow$ 權重 $= \beta(1-d)(p_{data}-q)$, 在 $q > p_{data}$ 處為負,即壓低。



forward KL **0.9269** reverse KL **1.8131** ☐☐☐☐ 34.9%

— p_{data} (雙峰目標) — q_{θ} (可訓練分布) | 推高力(藍 $\uparrow$) | 壓低力(紅 $\downarrow$) — 另一邊的 q_{θ} (虛線對照) — p_{ref} (判別器的參考分布)

DDO 在覆蓋程度上的位置

抬升與壓低分屬兩端



抬升項做的是 forward KL 的事(把質量搬向資料)，壓低項做的是 reverse KL 的事(從過剩區撤出質量)：

DDO 同時作用於兩端，多數方法只能佔一端。

DPO、DDO 與統一引導式

同一種參數化，兩個用途

	DPO	DDO
隱式參數化	$\text{reward} = \beta \log \frac{\pi_{\theta}}{\pi_{\text{ref}}}$	判別器 = $\sigma(\beta \log \frac{p_{\theta}}{p_{\text{ref}}})$
目標	偏好學習	分布對齊
資料	成對人類標註	原始訓練資料，無需配對

DDO 的最優解 ([Zheng et al., 2025](#)):

$$p_{\theta}^* \propto p_{\text{ref}}^{1-1/\beta} p_{\text{data}}^{1/\beta}$$


正是統一引導式方法表末列的指數形式。guidance 在推論期執行這次銳化，而 DDO 則把同一個操作寫進權重，這使得推論時不再需要第二次前向。

訓練到頂之後

MLE 收斂之後，指標仍有空間

Zheng et al. (2025) 微調多個提供 logprob 的生成模型，兩則觀察與本堂論證直接相關：

1. 繼續用 MLE 訓練，指標不動甚至劣化。forward KL 目標已到達其可達的極限；卡住的原因在目標函數，調參數解不開。
2. 有些模型此前靠 top-k / top-p 撐指標。截斷降低了有效溫度，把分布的缺陷藏起來而非修好；換上 DDO 後，不加任何截斷的原始分布品質即提升。



class-conditional CIFAR-10 第一輪微調(圖 6b、6c)。灰色虛線是繼續用 MLE 訓練, FID 由 1.85 起不降反升; 彩色線是不同超參數設置的 DDO, 1500 步內壓到 1.6 附近。

兩種輸出, 覆蓋程度的兩端

開場的兩欄，各自的位置



含糊的續寫出自 forward KL 訓練，同質的回答出自 reverse KL 對齊，分居覆蓋程度的兩端。這個位置可以在三個層次上調整：

- 訓練目標(選哪個散度)
- 解碼設定(temperature、top-p、guidance 係數)
- 權重微調(SFT、DPO、DDO 的 β)

本堂的假設, 與兩個未解的問題

兩個介面齊備，是全部論證的前提

本堂自始至終的假設： π_{ref} (以及 p_{θ}) 同時提供 `sample()` 與 `logprob(x)`。

兩個此刻沒有答案的問題：

1. reverse KL 一族缺 $p_{\text{data}}.\text{logprob}$ ，各方法拿什麼代理去補？本堂只見過 reward model 一種。
2. 一個完全不提供 `logprob` 的模型，要拿什麼訓練？

本堂總結

機率花式操作技巧

1. 介面決定可能性。一個分布至多提供 `sample()` 與 `logprob(x)`。
 p_{data} 只有前者，缺的失的 `logprob(x)` 正是模型的擬何目標。
2. 選散度就是選錯誤型態。forward KL 過度覆蓋、reverse KL 塌縮、JSD 飽和，三種失效都寫在目標函數裡。
3. 引導只有一條式子。 $\log p_{\text{guided}} = \log p_{\text{base}} + w (\log p_A - \log p_B)$.
temperature、CFG、classifier guidance、RLHF、DDO 都只是填欄位。
4. 推論期分四層。條件、抽樣、logits、聚合；第 1、4 層只需要 `sample()`，第 2、3 層要 `logprob(x)`。
5. 覆蓋程度可以在三個層次上調整。訓練目標、解碼設定、權重微調。

遇到沒看過的方法，第一個問題永遠一樣：它呼叫了哪一個介面。

