
生成模型導論（二）

建構滿足介面的分布

從操作分布到建構分布

上一堂的每一個結論，都以分布已經在手上為前提

	上一堂	這一堂
問題	兩個分布之間的距離怎麼定義	對模型與資料施加什麼約束
	手上已有的分布怎麼操作	分布怎麼解構成可訓練的部件
分布的地位	給定的抽象物件	要建構出來的 p_θ

分布 p 作為一個物件

`p.sample()` → 從 p 抽出一個樣本

`p.logprob(x)` → 回傳 $\log p(x)$

常見的生成模型有 AR(Autoregressive Model)、Flow(Normalizing Flow, NF)、VAE(Variational Autoencoder)、EBM(Energy-Based Model)、DPM(Diffusion Probabilistic Model)、GAN(Generative Adversarial Network) 這六種，它們分別以不同代價構造分布。

三個散度，三種補法

每一個缺口，對應一種工程回應

散度	需要的介面	代理	形成的家族
forward KL Kullback–Leibler	$p_{\text{data}}.\text{sample} + p_{\theta}.\text{logprob}$	不需要	MLE(Maximum Likelihood Estimation)：AR / Flow / VAE / DPM / EBM
reverse KL	$p_{\theta}.\text{sample} + p_{\theta}.\text{logprob} + p_{\text{data}}.\text{logprob}$	reward / energy	RLHF(Reinforcement Learning from Human Feedback)、VI(Variational Inference)
JSD Jensen–Shannon divergence	兩側 logprob	訓練一個分類器	GAN

兩種代理，同一個結構

reward model 與判別器並列

	reward model	GAN 判別器
代理對象	$p_{\text{data}}.\text{logprob}$ (偏好版)	$\log(p_{\text{data}}/p_g)$
輸入輸出	單一樣本 $\rightarrow$ 純量	單一樣本 $\rightarrow$ 純量
極限	逐點評分，無法表達「分布太窄」	同左

兩者都代替拿不到的 $p_{\text{data}}.\text{logprob}$ ，也繼承同一個結構極限：介面是逐點的，分布層級的資訊（覆蓋率、多樣性）沒有欄位可以通過。第一堂裡「 β 是唯一抑制塌縮的項」那個論證，對判別器一族同樣成立。

DDO 借用了哪一格

兩個 logprob 都在手上，卻仍造了一個判別器

DDO(Direct Discriminative Optimization) 屬於 forward KL 列，本來不需要任何代理。

它做的事是把 JSD 列的判別器構造搬進來：不另訓分類器，直接宣告 $\sigma(\beta \log(p_\theta/p_{\text{ref}}))$ 是判別器。

	抬升資料區	壓低過剩區
來源	forward KL 列的 MLE 項	JSD 列的判別式負例項

同時作用於覆蓋程度兩端的能力，正來自這次跨列的借用：介面齊備的家族，可以動用其他列的構造。

分類即介面能力

六個家族，兩個介面，一張矩陣

家族介面能力矩陣

同一列讀水平取捨，同一欄讀家族差異

家族	logprob	sample	訓練目標
AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 $\log Z$)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界,經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)

GAN 的空格解釋三件事

一個空格，三個後果

AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 log Z)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界;經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)

1. 訓練只能經過判別器代理：任何散度都需要密度資訊，GAN 一側拿不出來。
2. 上一堂以 logprob 為前提的方法全數不適用：統一引導式、DPO(Direct Preference Optimization)、DDO，對 GAN 一條都寫不出來。
3. 放棄正規化密度，換得架構自由：generator 不受可逆性、序列分解或任何密度簿記的約束，任意一步映射都合法，品質因此能在單步內達成。

同為 exact，差在 sample；同為分解，差在方向


三種 sample 形式的對照

	AR	NF	DPM
logprob	chain rule 逐項相加	變數變換公式	變分下界；經 probability flow ODE 精確
sample	逐維序列（慢、表達力強）	一步（快，但受可逆性約束）	多步迭代（步數即成本）
分解方式	沿維度	沿可逆層	沿雜訊尺度

AR 與 NF 的 logprob 同樣精確，形式不同；NF 證明了密度與一步生成可以共存，代價是每一層都必須可逆且 Jacobian 可算，表達力被此束縛。DPM 把一步生成拆成許多個子問題，每個子問題是一次簡單迴歸，品質與密度都保住，代價全數記在抽樣步數上。

家族樹

依訓練散度與 logprob 形式分層



分支的每一層都是介面問題：訓練散度可不可計算、logprob 以什麼形式提供、sample 要幾步。

介面契約：逐家族呼叫兩個介面 ↗

guide 強度 w 1.0

每張卡連取 30 點

清除畫布

00000 0 0 · guide 000: -

● **AR** $p(x_1) \cdot p(x_2 | x_1), \dots$

sample()

logprob(x)

guide(w)

00000000

● **Flow** $x = f(z), f \text{ 可逆} + \tanh$

sample()

logprob(x)

guide(w)

00000000

● **VAE** $\sum_k \pi_k N(x; \mu_k, \Sigma_k), k \in \{1, 2\}$

sample()

logprob(x)

guide(w)

00000000

● **GAN** $x = G(z), z \sim \mathcal{N}(0, I)$

sample()


logprob(x)

guide(w)

000 sample(): 00000000

樣本空間 $x \in \mathbb{R}^2$

藍點=雙月牙真實資料(僅供對照,四個玩具模型都沒有訓練)。彩色點=各模型 sample() 的輸出。按下某張卡的 logprob(x) 後,點畫布任一位置即可查詢該點的 log 密度。




● 真實資料 two moons ● AR 樣本 ● Flow 樣本 ● VAE 樣本 ● GAN 樣本

生成學習三難

sample quality • mode coverage • sampling speed

沒有家族三者兼得

六個家族，三條邊




三個目標同時滿足，目前沒有任何家族做到(Xiao, Kreis & Vahdat, 2022)。每個家族都落在某一條邊上：兩端是它拿到的目標，對面的頂點是它付出的代價，沿邊的位置是兩個目標之間的偏重。

中場 Q & A

AR

逐維分解，精確 logprob

AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 $\log Z$)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界;經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)



AR 的介面實作

一條恆等式，分解出每一項條件機率

$$\log p(x) = \sum_t \log p(x_t \mid x_{<t})$$

chain rule 把聯合分布拆成逐 token 條件機率的連乘；每一項都是一次 softmax 輸出，可以直接讀取。

介面	形式	代價
<code>logprob(x)</code>	精確，一次前向即得全部	幾乎免費
<code>sample()</code>	逐 token，天生序列	長度即延遲

AR：逐維生成，精確 logprob ↗

生成一點(分步)

連續生成

維度順序


先 x_1 再 x_2

↺ 清除生成點

```
0 . logprob
```


資料空間 $x \in \mathbb{R}^2$

藍點=資料(三群 Gaussian mixture)。橘紅點=已生成樣本。點任一位置即查詢該處的兩項 logprob 與總和。



步驟 1: 邊際 $p(x_1)$

第一維沒有任何條件可用,直接從邊際直方抽樣。橘紅的 bin = 本次抽中的值。



步驟 2: 條件 $p(x_2 \mid x_1)$

此曲線依步驟 1 的結果即時改變——這正是 sample 無法平行化的原因。

先抽出(或查詢)第一維,條件分布才存在

Cross-entropy(CE) 與 KL 的關係

兩者只差一項資料本身的熵

$$H(p, q) = H(p) + \text{KL}(p \parallel q)$$

項	定義	讀法
$H(p, q)$	$-\mathbb{E}_{x \sim p}[\log q(x)]$	拿 p 的樣本餵給模型 q ，取 $-\log q(x)$ 的平均，就是訓練時最小化的 loss
$H(p)$	$-\mathbb{E}_{x \sim p}[\log p(x)]$	資料本身的熵，只由 p 決定，換哪個模型都不變

語言建模最小化 CE，等價於最小化 forward KL：AR 家族落在 mode-covering 端的原因

$H(p_{\text{data}})$ 估不出來

資料的熵沒有無偏估計途徑

資料只有樣本、沒有密度。CE 的絕對值因此無法回答「離最優還有多遠」。

四條實務路線：

路線	作法
同資料比差值	$H(p)$ 是共同常數，模型間的 CE 差就是 KL 差
參考模型正規化	以另一個模型的 logprob 為基準（DDO 的 log ratio 即此形）
已知熵的合成資料	人造分布， $H(p)$ 可解析計算
繞開 likelihood	MAUVE、MMD(Maximum Mean Discrepancy)、下游任務指標

跨 tokenizer 的比較：BPB

換一個與詞表無關的單位

同一份文本，不同 tokenizer 切出的 token 數不同，per-token 的 CE 之間不可比。換算到位元組，以 BPB(Bits Per Byte) 為單位：

$$\text{BPB} = \frac{T}{N_{\text{bytes}}} \cdot \log_2 \text{PPL}_{\text{token}}$$

T 為 token 數、 N_{bytes} 為位元組數、PPL 為困惑度(Perplexity)：把「每 token 的困惑度」換算成「每位元組的位元數」，單位與 tokenizer 無關。

比較不同詞表的模型、或同模型換 tokenizer 前後，以 BPB 為準。

訓練目標的精確形狀

forward KL 沿序列分解（對兩邊同時用 chain rule）

$$\text{KL}(p \parallel q) = \sum_t \mathbb{E}_{x_{<t} \sim p} \left[\text{KL}(p(\cdot \mid x_{<t}) \parallel q(\cdot \mid x_{<t})) \right]$$

注意期望的下標：**前綴取自 p** ，也就是資料。

teacher forcing（訓練時餵真實前綴）是這個分解的直接實作，而非工程上的權宜。

Exposure bias：目標從未度量的那條軌跡

訓練與生成走在不同的前綴上



訓練目標只在藍色軌跡上取期望;橘色軌跡上的條件分布從未被度量。

reverse KL 的分解要把前綴分布與每步引數同時對調： $\text{KL}(q \parallel p) = \sum_t \mathbb{E}_{x_{<t} \sim q} [\text{KL}(q(\cdot \mid x_{<t}) \parallel p(\cdot \mid x_{<t}))]$ 。訓練目標裡沒有任何一項在 q 的前綴上取期望；模型自己生成的軌跡，損失函數從未在那裡取過期望。memory agent 長對話品質漂移的機制之一即在此。DDO 的壓低項恰好在 p_{ref} 的樣本（即 q 系的軌跡）上施力，補的正是這一塊。

訓練軌跡與自由生成軌跡的分離 ↗

資料集 圓 Circle(k=1 就夠) ▼

k(context window)

1

ϵ (scheduled sampling)

0.00

訓練速度

5

☐ 訓練

σ (rollout 每步微擾)

0.000

⏸ 暫停


↺ 重設模型

⚡ 擾動 rollout

step 0 ☐ RMSE 0.157 rollout ☐ -

資料空間 $x \in \mathbb{R}^2$ (可點擊重啟 rollout)

藍點=真實軌跡(深淺為時間相位)。深藍箭頭=每個真實點上的一步預測(前綴取自資料=訓練軌道)。橘紅軌跡=模型自己跟自己的 rollout(前綴取自模型=推論軌道)。◎=歧義點。



● 真實軌跡 ● 一步預測 ● rollout ◎ 歧義點 ● 擾動

偏離 vs. rollout 步數(誤差複利)

每回合 rollout 的離流形距離,隨步數畫成一條線;淡線=之前幾回合。藍色虛線=一步 RMSE;若誤差不複利,曲線應停在虛線附近。


1.07



● 本回合 ● 先前回合 -- 一步 RMSE

訓練曲線(同單位可比,log 尺度)

一步 RMSE(teacher-forced,訓練 loss 實際測的量)與 rollout 平均偏離(推論實際發生的量)。兩線的落差就是 exposure bias。



● 一步 RMSE ● rollout 平均偏離

False premise：結構裡沒有拒答

條件分布不知道自己的條件有多罕見

$p(y | x)$ 對任何 x 都良定義，包括 $p(x) \approx 0$ 的荒謬前提。

- forward KL 訓練獎勵「在資料上覆蓋」，語料裡的問題幾乎都伴隨回答；拒答作為輸出模式，結構上沒有位置，除非 post-training 明文補上（[Kalai et al., 2025](#) 從訓練目標與評測誘因分析幻覺的必然性）
- 「 $p(y | x)$ 算得出來」與「 x 值得回答」是兩個獨立命題；false premise 偵測要判定的是後者（基準： $(QA)^2$ ，Question Answering with Questionable Assumptions，[Kim et al., 2023](#)）

AR 的改進史

四步在品質與覆蓋，最後一步移動覆蓋程度

n-gram

計數即條件機率；脈絡長度受限於統計強度

RNN / LSTM 品質

recurrent neural network 與 long short-term memory：參數化條件分布，脈絡不再截斷

attention → Transformer 2017 品質

訓練可平行，scaling 自此可行

scaling laws 2020 品質・覆蓋

損失隨規模幂律下降，投資有可預測回報(Kaplan et al.)

instruction tuning / RLHF 2022 覆蓋程度右移

往 mode-seeking 端移動：可用性換多樣性

速度側與應用

序列抽樣的兩種提速

序列生成的提速（sample 介面的補強）：


- speculative decoding：小模型先猜、大模型驗收，可證明不改變輸出分布
- multi-token prediction：一次前向押注多個 token

應用：對話與 agent、程式生成，以及 LLM-ASR(Large Language Model + Automatic Speech Recognition) 裡作為預訓練 backbone 提高辨識能力。

Normalizing Flow

可逆變換，一步抽樣

AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 $\log Z$)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界;經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)



NF 的介面實作

以可逆變換把標準高斯映射到資料分布，變數變換公式給出精確密度

$$\log p_x(x) = \log p_z(f^{-1}(x)) + \log |\det J_{f^{-1}}(x)|$$

- 行列式項是體積修正：空間被拉伸處密度變稀、壓縮處變密，總機率守恆
- `logprob(x)`：逆向映射得 z 、查 base 密度、累加各層 log-det，精確值三步到手
- `sample()`： $z \sim \mathcal{N}(0, I)$ ，前向一步

任意 $D \times D$ 行列式要 $O(D^3)$ ；NF 以架構設計讓 Jacobian 呈三角形，行列式退化為對角線連乘，降為 $O(D)$ 。離散 NF 的架構史，大半是三角結構的設計史。

Normalizing Flow：可逆變換與精確密度 ↗

目標分布 p_{data}

雙月 Two Moons

層數

4

層 k

0.6

☒ 自動播放

訓練速度

4


▶ 開始訓練

↺ 重設模型

step 0 k 1/4 NLL - bits/dim

可逆變換: $N(0, I) \rightarrow (\text{前 } k \text{ 層}) \rightarrow p_{data}$

灰色網格= z 空間的規則座標網,被前 k 層變換扭曲。彩色粒子=一批 z 樣本被推到第 k 層的位置; $k=L$ 時就是**生成樣本**(一步完成)。注意網格會拉伸、彎折,但**永不撕裂或重疊**——這就是可逆的意思。




● 生成樣本(依 z 角度著色) ● 目標資料 ● 被扭曲的 z 網格

● 探測點的反推路徑

精確密度 $\log p(x)$ (可點擊/拖曳)

每一格都是一次 inverse pass 算出的**精確** $\log p(x)$ (change of variable),不是判別器分數、也不是 ELBO。**點擊任一位置**叫 logprob 介面:讀出數值,並在左圖畫出 x 逐層反推回 z 的路徑。熱圖隨隨 k 滑桿,顯示前 k 層的 pushforward 密度。




□□□□□□□□ → □□ $\log prob(x)$

● 低 → 高 ☒ 疊資料點

精確 NLL 損失

直接最小化 $-\log p_{\theta}(x)$ (forward KL/ MLE),無對抗、無下界。這條曲線的數值**本身有意義**:換算成 bits 後可跨模型比較——與 AR 的 BPB 是同一個單位,GAN 的 loss 做不到這件事。



● NLL(bits/dim)

介面成本的權衡

自迴歸把成本推到一側，coupling 兩側同時便宜

	MAF masked autoregressive flow	IAF inverse autoregressive flow	Coupling (NICE / RealNVP / Glow)
依賴結構	逐維，條件於 $x_{1:i-1}$	逐維，條件於 $u_{1:i-1}$	二分區塊，一半條件另一半
logprob	一次並行評估 (快)	逐維還原 u ， $O(D)$ 串行 (慢)	一次並行評估 (快)
sample	逐維串行 $O(D)$ (慢)	一次抽 u ，並行生成 (快)	一次並行生成 (快)
缺點	生成慢，長度即延遲	外部樣本 logprob 慢，難以 MLE 訓練	每層只動一半維度，靠深度補表達力
適用	密度估計、MLE 訓練	即時生成、變分後驗	通用密度估計與影像生成

連續化：行列式退化為跡

層數趨於無窮的極限是一條常微分方程

$$\frac{dz}{dt} = f(z, t), \quad \frac{d \log p(z(t))}{dt} = -\text{Tr} \left(\frac{\partial f}{\partial z} \right)$$

- Neural ODE(Ordinary Differential Equation)([Chen et al., 2018](#))：非線性的行列式在連續極限下換成線性的跡： $O(D^3) \rightarrow O(D)$ ，架構約束隨之解除
- 可逆性免費取得：向量場 Lipschitz 連續則軌跡不相交(Picard–Lindelöf)，不再需要 coupling 結構
- FFJORD(Free-form Jacobian of Reversible Dynamics)：Hutchinson 估計跡，免建 Jacobian([Grathwohl et al., 2018](#))
- 代價：MLE 訓練的每一步都要呼叫數值 ODE solver，慢且不穩

NF 的特徵性失效與今日角色

分布外樣本的悖論、結構限制，與今日的應用領域

OOD(Out-Of-Distribution) 悖論：在複雜影像上以 MLE 訓練的 NF，常給沒見過的更簡單影像更高的 log-likelihood(Nalisnick et al., 2019)：forward KL 只要求資料處機率高，不禁止別處更高；低複雜度影像經可逆映射聚在高斯原點附近的高密度區。精確似然與可靠的 OOD 偵測是兩件事。


結構限制：可逆映射不能改變拓撲；維度必須全程保持，無法下採樣壓縮；單層表達力弱，迫使極深堆疊。

今日角色：語音 vocoder（WaveGlow 並行生成）、科學計算（Boltzmann Generators 一步抽分子平衡態）、變分後驗(IAF)、模擬推斷與宇宙學。

VAE

latent 變數，下界訓練

AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 $\log Z$)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界;經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)



VAE 的介面實作

以下界取代不可解的邊際似然

引入 latent z : $p_{\theta}(x) = \int p_{\theta}(x | z) p(z) dz$, 積分不可解 , 改而最大化證據下界(Evidence Lower Bound, ELBO) :

$$\log p_{\theta}(x) \geq \text{ELBO} = \mathbb{E}_{q_{\phi}(z|x)} [\log p_{\theta}(x | z)] - \text{KL}(q_{\phi}(z | x) \| p(z))$$

介面	形式
<code>logprob(x)</code>	僅下界(ELBO) ; 與真值的差是 $\text{KL}(q_{\phi} p_{\theta}(z x))$
<code>sample()</code>	$z \sim p(z)$, decoder 一次前向

特徵性失效：過度平滑

Gaussian 重建項與 mode-covering 的疊加

重建項用 Gaussian likelihood 時， $\log p_{\theta}(x | z)$ 等價於負的均方誤差(Mean Squared Error, MSE)；MSE 的最優解是**條件均值**：多個可能輸出的平均，而非其中任何一個。

疊上 mode-covering 的訓練目標，結果是樣本模糊、細節被抹平：兩個機制往同一個方向推。

這是失效型態由訓練目標決定的又一例：模糊寫在 Gaussian $\times$ forward KL 這個組合裡，調架構調不掉。

VAE：過度平滑、拓撲、 β 的兩端 ↗

資料集

雙月 Two Moons



β (KL 權重)



1.0

訓練速度



4

▶ 開始訓練

↺ 重設模型


☒ 生成樣本

☒ 解碼網格

step 0 □□ - KL -

資料空間 $x \in \mathbb{R}^2$


彩色點=真實資料(顏色為資料的內在座標)。橘紅點=從先驗 $z \sim N(0, I)$ 解碼的生成樣本。網格=解碼器把潛在空間的方格「摺」進資料流形的樣子。



● 真實資料 ● 生成樣本 ● 點選的 z 解碼結果

潛在空間 $z \in \mathbb{R}^2$ (可點擊/拖曳)


每個點是資料經 encoder 得到的 $\mu(x)$, 顏色與左圖對應。虛線圓=先驗 $N(0, I)$ 的 1σ 、 2σ 。KL 項就是在把這團點「推」進圓裡。



○ 先驗 $N(0, I)$ ● 選取的 z

損失曲線

ELBO 的兩項:**重建誤差**(還原得像不像)與 **KL 散度**(潛在分布貼不貼近先驗)。調 β 立刻能看到兩者的消長。



● 重建 MSE ● KL

VAE 的改進史與今日角色

三步對付模糊，最後轉為基礎設施


- **β -VAE** 2017 控制
調 KL 項係數，換 disentanglement(Higgins et al.)
- **VQ-VAE** 2017 結構
vector quantized VAE，離散 latent：decoder 無法忽略，繞開 posterior collapse(van den Oord et al.)
- **VQ-GAN** 2021 品質
vector quantized GAN：加對抗損失，重建變銳利(Esser et al.)
- **壓縮器角色** □□ 基礎設施
Stable Diffusion 在 VAE latent 空間跑 diffusion

應用：表徵學習、異常偵測（ELBO 作為異常分數），以及作為其他生成模型的 latent 基礎設施。

GAN

一步映射，沒有密度

AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 $\log Z$)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界;經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)



GAN 的介面實作

只有 sample，沒有密度簿記

$$x = G(z), \quad z \sim \mathcal{N}(0, I)$$

一步映射，只有 `sample()`。 G 不維護任何密度，logprob 那一欄是空的：

- 訓練只能透過判別器代理（本堂開頭的代理表）
- 統一引導式、DPO、DDO 全部以 logprob 為前提，對 GAN 無一適用
- 換得的是不受可逆性與序列分解約束的 generator 架構

理論上的 JSD，實務上的別種東西

換掉損失，也換掉了對應的散度

$2 \text{JSD} - 2 \log 2$ 只在最優判別器處成立，而那裡正是梯度消失的位置（JSD 飽和）。實務改用 non-saturating 損失，對應的散度變成(Arjovsky & Bottou, 2017)：

$$\text{KL}(p_g \parallel p_{\text{data}}) - 2 \text{JSD}(p_g \parallel p_{\text{data}})$$

	原始 minimax	non-saturating
對應散度	JSD	reverse KL — $2 \cdot \text{JSD}$
病理	梯度消失	mode-seeking、易塌縮

換損失治好了梯度消失，也一併換掉了 mode-covering：每種損失各配一種失效。

Mode collapse 的第一層成因

覆蓋率沒有進入 generator 收到的訊號

generator 的損失裡**沒有資料項**： G 只從 D 的評分獲得訊號，而 D 逐點評分。

覆蓋率是分布層級的性質；逐點介面沒有承載它的欄位。漏掉一整個眾數時，只要現有樣本能騙過 D ，損失就不會抗議。

與 reward model 的結構極限同構：兩個逐點代理，同一個限制。第一堂裡抑制塌縮的只剩 β ；這裡連 β 都沒有。

對症的修補是給介面加欄位：minibatch discrimination 把 batch 內樣本相似度的總和直接接進判別器的輸入，塌縮批次立即被抓([Salimans et al., 2016](#))。

Mode collapse：判別器地景看得見，generator 收不到 ↗

資料集

高斯混合 ×6

D 更新次數 / G 一次

1

訓練速度

4

▶ 開始訓練

↺ 重設模型

☒ 生成樣本


☒ 生成器網格

☐ 左圖疊上 D 地景

step 0 D(real) - D(fake) -

資料空間 $x \in \mathbb{R}^2$


藍綠色點=真實資料。橘紅點= $G(z)$, $z \sim N(0, I)$ 的生成樣本。網格=生成器把潛在空間的方格映射進資料空間的樣子——**mode collapse 發生時**，整張網格會塌縮到少數幾個點。



● 真實資料 ● 生成樣本 $G(z)$

判別器地景 $D(x)$ (可點擊查詢)


整個平面上 D 的輸出: 藍=判為真、橘紅=判為假。生成器會被推往藍的地方; D 又會把生成點附近「壓成橘紅」。點擊任一位置查詢 $D(x)$ 的數值。



● $D(x)$: 0(橘紅, 假) → 1(藍, 真) ● 查詢的點

損失曲線 (注意: 不會單調下降)

對抗訓練是賽局而非最佳化單一目標: 兩條曲線互相拉扯、震盪是常態。健康的訊號不是 loss 變低, 而是 $D(\text{real})$ 、 $D(\text{fake})$ 同時徘徊在 0.5 附近。



● D loss ● G loss (non-saturating)

判別器想法的單向轉移

借用只在一個方向上成立

第一堂 DDO 的原型即是這裡的 $d^* = p/(p + q)$ ：「用自身 logprob 造判別器」把 GAN 的核心構造搬進了 logprob 家族。

方向	可行性
判別器構造 → logprob 家族(DDO)	可行：log ratio 直接可算，無需另訓網路
logprob 方法 → GAN	不可行： p_θ 寫不出來，式子無從成立

介面多的一方可以借介面少的一方的構造，反向沒有著力點。

GAN 的改進史與今日角色

穩定、品質、規模，最後轉向蒸餾


- **DCGAN** 2015 品質
deep convolutional GAN：穩定可複製的卷積配方(Radford et al.)
- **conditional GAN** 控制
條件化生成
- **WGAN** 2017 穩定
Wasserstein GAN：Earth Mover 距離替代 JSD，支撐集分離時仍有梯度(Arjovsky et al.)
- **StyleGAN** 2019 品質
品質與可控性(Karras et al.)
- **BigGAN** 2019 品質
大規模訓練(Brock et al.)
- **蒸餾目標** 速度
少從頭訓練；把多步模型壓成一步的對抗式蒸餾

應用：低延遲與即時場景、超解析、風格與語音轉換、diffusion 的加速蒸餾。

Energy-Based Model

未正規化的密度，MCMC(Markov Chain Monte Carlo) 抽樣

AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 $\log Z$)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界;經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)



EBM 的介面實作

能量給出相對機率， $\log Z$ 攔住絕對值

$$p(x) = \frac{e^{-E(x)}}{Z}, \quad Z = \int e^{-E(x)} dx$$

任意純量網路都可以當 E ：低能量即高機率，約束最少的一種參數化。

介面	形式
<code>logprob(x)</code>	只到未正規化為止： $-E(x) - \log Z$ ，而 $\log Z$ 算不出來
<code>sample()</code>	原生沒有：靠 Langevin dynamics 逐步迭代逼近

Z 有多難： $224 \times 224 \times 3$ 的二值影像要對 $2^{150528} \approx 10^{45000}$ 個狀態加總。相對比較則不受影響：兩點的 $-E$ 之差就是 $\log$ 機率比， $\log Z$ 相消。

EBM：能量地景與 Langevin 抽樣 [↗](#)

能量函數

近距雙峰

遠距雙峰

環形谷

▶ 啟動

單步

↺ 重設

步長 η

0.0050

溫度 T


1.00

每幀步數

1

能量地景 $E(x), x \in \mathbb{R}^2$

深色=低能量(谷),等高線間距固定;橘紅點=20 條 Langevin 鏈與其軌跡。點擊畫布任一位置可查詢該點能量。



讀數

跨峰:鏈的落點由一峰移到另一峰(峰間 $|x_1| < 0.25$ 的緩衝帶不計,避免抖動灌水)。

步數

0

各峰鏈佔比(左 / 右)

50% / 50%

最近 500 步內跨峰

0 □ · 0 □□

□□□□□□□□:□□□□ $-E(x)$, □□□ $\log p(x) = -E(x) - \log Z(Z \square \square) \square$

沒有 log Z，怎麼訓練

MLE 梯度拆成兩個相位（ $-\nabla_{\theta} \log Z$ 化為對模型分布的期望）

$$\nabla_{\theta} \log p(x) = \underbrace{-\nabla_{\theta} E(x)}_{\text{data}} + \underbrace{\mathbb{E}_{x' \sim p_{\theta}} [\nabla_{\theta} E(x')]}_{\text{model}}$$

方法	手法	對應的差異度量
Contrastive Divergence Hinton, 2002	鏈從資料點起跑只走 k 步； $\log Z$ 梯度對消	$\text{KL}(p_{\text{data}} p_{\theta}) - \text{KL}(p_k p_{\theta})$
Score matching Hyvärinen, 2005	改對 x 微分： $\nabla_x \log Z = 0$ ， Z 直接消失	Fisher divergence
NCE noise contrastive estimation • Gutmann & Hyvärinen, 2010	與已知雜訊分布做二元分類， Z 當可學純量	BCE(Binary Cross Entropy)（漸近 KL）

EBM 的特徵性失效

抽樣、混合、穩定性、評估

- **抽樣即成本**：一次生成要數百至數千步 Langevin，每步一次前向加反向；對照一次前向即生成的家族，ImageNet 規模的訓練時間由小時級膨脹至年級
- **Mode mixing**：眾數間隔著高能量障壁時，鏈困在單一能量谷，mixing time 隨障壁高度指數成長，各眾數的比例難以還原
- **訓練發散**：能量無上界約束，OOD 區域會長出訓練資料中不存在的假能量井，sampler 掉入後訓練崩壞；與 BatchNorm 尤其不相容
- **評估困難**：exact likelihood 不存在，只能以 Annealed Importance Sampling 等昂貴近似

EBM 的改進史與今日角色

從 Hopfield 到 JEM(Joint Energy-based Model)


- **Hopfield 網路 • Boltzmann Machine** 1982–85 **概念**
能量地景支配網路狀態；隨機隱單元(Hopfield;Ackley, Hinton & Sejnowski)
- **RBM** 1986 **可訓練**
restricted Boltzmann machine：二部圖限制使 Gibbs sampling 可行(Smolensky)
- **Contrastive Divergence** 2002 **訓練**
短鏈繞過平衡態；2006 年疊層預訓練帶動深度學習復興(Hinton)
- **深度 ConvNet 能量函數** 2016 **品質**
現代網路參數化 E(Xie et al.)
- **ImageNet 規模** 2019 **規模**
replay buffer 穩定 SGLD，stochastic gradient Langevin dynamics(Du & Mordatch)
- **JEM** 2020 **統一**
任何 softmax 分類器都暗含 EBM： $E(x) = -\text{LogSumExp}(\text{logits})$ (Grathwohl et al.)

今日角色： $\text{score} = -\nabla_x E$ ，能量地景的梯度場；OOD 與異常偵測(energy score)、機器學習勢能面（分子模擬）、序列級重排序（residual EBM 對整句評分，緩解逐 token 生成的誤差累積）。

DPM / Flow Matching

多步分解，每步一次迴歸

AR	精確(chain rule)	逐 token 序列(慢)	forward KL / MLE
Normalizing Flow	精確(變數變換,需可逆 + Jacobian)	一步	forward KL / MLE
VAE	僅下界(ELBO)	一步	forward KL 的下界
EBM	未正規化(差 $\log Z$)	MCMC 多步(慢)	forward KL(MCMC 梯度)/ score matching
DPM / FM	下界;經 probability flow ODE 精確	多步迭代(慢)	forward KL 的另一種分解
GAN	無	一步	JSD(理論)/ non-saturating(實務)



DPM 的介面實作

把生成拆成一疊簡單迴歸

AR 沿**序列**分解 forward KL；DPM 沿**雜訊尺度**分解同一個散度：把資料逐步加入雜訊直到成為純雜訊，模型學每一小步的還原。

- 每一步是一次簡單迴歸（預測雜訊或速度場），訓練穩定性與 AR 相當
- `logprob(x)`：有變分下界；經 probability flow ODE 可精確計算([Song et al., 2021](#))
- `sample()`：多步迭代，一步一次前向

同一個 forward KL，兩種切法：AR 切在維度之間，DPM 切在訊噪比之間。

特徵性失效：慢

優勢幾乎全數以抽樣步數支付

一張樣本要跑幾十到上千次前向。

矩陣裡 DPM 的 sample 欄與三難裡 DPM 的位置說的是同一件事；於是這個家族的改進史，大半是一部**減步數**的歷史。

改進史（上）：從千步到少步

三篇論文，步數降兩個量級

- **DDPM** 2020 品質・覆蓋

denoising diffusion probabilistic models：離散時間逐步去噪，千步量級(Ho et al.)

- **DDIM** 2020 速度

denoising diffusion implicit models：非 Markov 過程族， $\eta=0$ 得確定性抽樣；已訓練的 DDPM 權重免重訓，步數大減(Song et al.)

- **Score-based SDE** 2021 理論統一

離散步驟統一成連續時間 SDE(stochastic differential equation)；probability flow ODE 由此而來(Song et al.)

CFG(Classifier-Free Guidance) 與 zero-shot 編輯

統一引導式在這個家族的原始形式([Ho & Salimans, 2022](#))

$$\log p_w = \log p(x | c) + w(\log p(x | c) - \log p(x))$$

其中一類 zero-shot 編輯直接套用這個形式： p_A 條件於原圖、 p_B 為無條件分布、 w 控制改動幅度。InstructPix2Pix 的雙 guidance scale（影像一個係數、指令一個係數）是此式加到兩個比值項的推廣，每個條件各配一個係數([Brooks et al., 2023](#))。

不需重訓、不需配對資料：同一個係數，在影像家族裡調的是「聽指令的程度」。

改進史（下）：換空間、換目標、換步數

latent 空間、速度場、一步蒸餾

- **Latent Diffusion** 2022 速度
在 VAE latent 空間跑 diffusion，算力降一個量級(Rombach et al.)
- **Flow Matching / Rectified Flow** 2023 簡化
continuous normalizing flow(CNF) 的免模擬訓練法：在插值路徑上直接迴歸速度場；源分布不必是 Gaussian(Lipman et al.;Liu et al.)
- **Consistency Models / 對抗式蒸餾** 2023 速度
多步 ODE 積分蒸餾成一步(Song et al.)；對抗式蒸餾另見 ADD，adversarial diffusion distillation(Sauer et al.)

Latent Diffusion 的壓縮層即 VAE 段的收尾；一步蒸餾的對抗損失即 GAN 段的今日角色：三個家族在這條時間軸上會合。

另一條提速路線：改權重，不減步數

省下的是每步的第二次前向

對原以 CFG 推論的模型，DDO 微調後免 guidance 的品質超過原 CFG 基線，每步省下一次前向（[Zheng et al., 2025 專案頁](#)）；下表為免 guidance 的前後對照：

模型	資料集	FID(Fréchet Inception Distance) (前 → 後，無 guidance)
EDM	CIFAR-10	1.79 → 1.30
EDM2	ImageNet-64	1.58 → 0.97
EDM2	ImageNet 512×512	1.96 → 1.26
VAR-d30 (AR 家族)	ImageNet 256×256	4.74 → 1.79

每輪微調成本低於預訓練 epoch 數的 1%，可 self-play 疊代。上一堂兩則定性觀察（MLE 到頂、截斷藏缺陷）的數字版即在此表。

Flow Matching：同一個散度的另一種分解 ↗

來源分布 p_0

高斯 $N(0, I)$

目標分布 p_1

雙月 Two Moons

時間 t

0.15

☒ 自動播放

訓練速度

4

▶ 開始訓練


↺ 重設模型

☒ 軌跡

step 0 FM loss -

傳輸過程: $p_0 \rightarrow (t) \rightarrow p_1$


橘紅粒子=一批來源樣本,沿學到的速度場積分到目前時間 t 。綠點=它們的出發位置,藍點=目標資料。 $t=1$ 時的粒子就是**生成樣本**。粒子一律用橘紅色,與來源、目標的顏色區分開。



● 傳輸中的粒子 ● 目標資料 p_1 ● 出發位置 p_0

速度場 $v(x, t)$ (可點擊/拖曳)


箭頭=目前時間 t 的速度場,越深代表速度越大。點擊任一位置:深色路徑顯示「一顆此刻在這裡的粒子」會被場帶去哪(積分到 $t=1$)。拖動 t 滑桿,看整個場如何隨時間變形。



● 慢 → ● 快 ● 選取的起點與其路徑

Flow Matching 損失

單純的回歸 MSE: $\|v_\theta(x_t, t) - (x_1 - x_0)\|^2$ 。沒有對抗、沒有 KL——注意它像一般監督學習一樣**平穩下降**,對比 GAN 的震盪。



● FM MSE

總結

六個家族的優缺點與適用場景

六個家族的優缺點

長處與代價都寫在兩個介面上

家族	優點	缺點
AR	logprob 精確且便宜，訓練穩定，離散資料天生適用	生成逐維串行，長度即延遲；自由生成會偏離訓練分布
NF	logprob 精確，一步生成，映射可逆	每層都要可逆且 Jacobian 可算，表達力受此束縛
VAE	一步生成，訓練穩定，latent 可供下游使用	logprob 只有下界；條件均值造成重建模糊
GAN	一步生成，品質銳利，架構不受密度簿記約束	沒有 logprob；訓練不穩，易 mode collapse
EBM	能量函數形式自由，多個能量可直接相加組合	$\log Z$ 不可算，訓練與抽樣都要 MCMC
DPM / FM	品質與覆蓋兼顧，訓練穩定，可用引導式控制	抽樣多步，速度是它的短邊

六個家族的適用場景

先看題目要哪個介面，再看能付多少步數

家族	什麼題目找它	代表用途
AR	離散序列，且需要密度讀數	語言與程式生成、n-best rescoring、偵測與校準
NF	要精確密度，又要一步生成	變分後驗、語音 vocoder、分子平衡態、模擬推斷
VAE	要表徵或壓縮，不追求逐點品質	異常偵測、擴散模型的 latent 空間基礎設施
GAN	單步就要高品質，且不需要密度	影像轉換與超解析、把多步模型蒸餾成一步
EBM	對既有分布做修正或整體評分	序列級重排序、OOD 偵測、分子勢能面
DPM / FM	連續訊號的高品質生成與可控編輯	影像、影片、音訊、分子設計、動作生成

選家族就是選介面

先問題目要 sample 還是 logprob、要哪一種形式；再問能付多少抽樣步數。兩個問題答完，六選一就只剩一兩個候選。

沒有一個家族三難全拿；每一次選擇都是拿一個目標換另一個，而換掉的是什麼，寫在它的兩個介面上。

參考文獻(1/2)

散度、引導、對齊、條件化

散度與機率背景

- [Stanford CS236](#), Lectures 1–2
- Bishop & Bishop, [Deep Learning: Foundations and Concepts](#)
- Endres & Schindelin (2003), [A New Metric for Probability Distributions](#)
- Arjovsky & Bottou (2017), [Towards Principled Methods for Training GANs](#)

引導與解碼

- Holtzman et al. (2020), [The Curious Case of Neural Text Degeneration](#)
- Li et al. (2023), [Contrastive Decoding](#)
- Chuang et al. (2024), [DoLa](#)
- Sanchez et al. (2023), [Stay on Topic with Classifier-Free Guidance](#)
- Ho & Salimans (2022), [Classifier-Free Diffusion Guidance](#)
- Karras et al. (2024), [Autoguidance](#)

對齊與 DDO

- Ouyang et al. (2022), [InstructGPT](#)
- Rafailov et al. (2023), [Direct Preference Optimization](#)
- Kirk et al. (2024), [Understanding the Effects of RLHF](#)
- Zheng et al. (2025), [Direct Discriminative Optimization](#)(ICML)
- Chen et al. (2024), [SPIN](#)

條件化與量測

- Xie et al. (2022), [In-context Learning as Implicit Bayesian Inference](#)
- Liu et al. (2024), [Lost in the Middle](#)
- Wang et al. (2023), [Self-Consistency](#)
- Kalai et al. (2025), [Why Language Models Hallucinate](#)
- Kim et al. (2023), [\(QA\)²: Question Answering with Questionable Assumptions](#)

參考文獻(2/2)

分類、三難，與各家族的演進

分類與三難

- Tomczak, [Deep Generative Modeling](#), 2nd ed. (2024)
- Xiao, Kreis & Vahdat (2022), [Generative Learning Trilemma](#)

家族演進

- Kaplan et al. (2020), [Scaling Laws](#)
- Higgins et al. (2017), [\$\beta\$ -VAE](#) ; van den Oord et al. (2017), [VQ-VAE](#) ; Esser et al. (2021), [VQ-GAN](#)
- Radford et al. (2015), [DCGAN](#) ; Arjovsky et al. (2017), [WGAN](#) ; Karras et al. (2019), [StyleGAN](#)
- Metz et al. (2017); Salimans et al. (2016)

Normalizing Flow

- Dinh et al. (2014), [NICE](#) ; Dinh et al. (2016), [RealNVP](#) ; Kingma & Dhariwal (2018), [Glow](#)
- Kingma et al. (2016), [IAF](#) ; Papamakarios et al. (2017), [MAF](#) ; van den Oord et al. (2018), [Parallel WaveNet](#)
- Chen et al. (2018), [Neural ODE](#) ; Grathwohl et al. (2018), [FFJORD](#)
- Nalisnick et al. (2019)

Energy-Based Model

- Hopfield (1982); Ackley, Hinton & Sejnowski (1985) ; Smolensky (1986), [RBM](#)
- Hinton (2002), [CD](#); Hyvärinen (2005) ; Gutmann & Hyvärinen (2010), [NCE](#)
- Xie et al. (2016); Du & Mordatch (2019) ; Grathwohl et al. (2020), [JEM](#)

Diffusion / Flow Matching

- Ho et al. (2020), [DDPM](#) ; Song et al. (2020), [DDIM](#)
- Song et al. (2021), [Score-SDE](#); Song & Ermon (2019)
- Rombach et al. (2022), [Latent Diffusion](#)
- Lipman et al. (2023), [Flow Matching](#) ; Liu et al. (2023), [Rectified Flow](#)
- Song et al. (2023), [Consistency Models](#) ; Sauer et al. (2023), [ADD](#)
- Brooks et al. (2023), [InstructPix2Pix](#)

